

Engenharia de Software 3.0: Uma Análise Empírica da Manutenibilidade de Contribuições de Agentes Autônomos de IA em Repositórios Open Source no GitHub

Arthur Curi, Helio Ernesto, João Campos, Lucas Azevedo,
Luiz Saud, Nicolás Chabot, Raphael Brito, Yan Cota

¹Instituto de Ciências Exatas e Informática (ICEI)
Pontifícia Universidade Católica de Minas Gerais (PUC Minas)
Belo Horizonte — MG — Brasil

Abstract. *This paper investigates the maintainability of contributions generated by autonomous Artificial Intelligence agents in open source GitHub repositories, comparing them with human contributions. Using the AIDev-pop corpus and the Goal-Question-Metric (GQM) approach, the study analyzes three dimensions: structural code maintainability, post-merge indicators, and structural technical debt. From 252,215 classified PRs, the analysis dataset comprises 202,014 PRs: only 9 in the AI Group (G1) and 202,005 in the Human Group (G2); 50,201 ambiguous PRs (G3) were excluded. **None of the seven research-question hypotheses were rejected after correction for multiple tests** (Benjamini-Hochberg and Bonferroni). The only variable showing a robust difference was the language distribution (Chi-square, adjusted $p = 0,0236$), a descriptive control with negligible effect size. Raw signals — higher cyclomatic complexity, lower Maintainability Index, and fewer test files in G1 — did not survive correction and rest on a very small G1 sample ($n = 9$; $n = 3$ for static code metrics), which severely limits statistical power and external validity.*

Resumo. *Este artigo investiga a manutenibilidade de contribuições geradas por agentes autônomos de Inteligência Artificial em repositórios open source no GitHub, comparando-as com contribuições humanas. Utilizando o corpus AIDev-pop e a abordagem Goal-Question-Metric (GQM), o estudo analisa três dimensões: manutenibilidade estrutural do código, indicadores pós-merge e dívida técnica estrutural. De 252.215 PRs classificados, o dataset de análise compreende 202.014 PRs: apenas 9 no Grupo IA (G1) e 202.005 no Grupo Humano (G2); 50.201 PRs ambíguos (G3) foram excluídos. **Nenhuma das sete hipóteses das questões de pesquisa foi rejeitada após correção para múltiplos testes** (Benjamini-Hochberg e Bonferroni). A única variável com diferença robusta foi a distribuição de linguagens (Qui-quadrado, p ajustado $= 0,0236$), um controle descritivo com tamanho de efeito negligível. Sinais brutos — complexidade ciclomática mais alta, Maintainability Index mais baixo e menor proporção de arquivos de teste em G1 — não sobreviveram à correção e baseiam-se em uma amostra G1 muito pequena ($n = 9$; $n = 3$ para métricas estáticas de código), o que limita severamente o poder estatístico e a validade externa.*

1. Introdução

A adoção de agentes autônomos de Inteligência Artificial no desenvolvimento de software tem crescido rapidamente nos últimos anos, configurando o que vem sendo denominado de Engenharia de Software 3.0 [Li et al. 2025] — estágio em que sistemas baseados em modelos de linguagem passam a participar ativamente de atividades como interpretar issues, escrever código, submeter Pull Requests e interagir com revisores humanos [Vaithilingam et al. 2022, Finnie-Ansley et al. 2023]. Esses agentes operam de forma cada vez mais autônoma, levantando questões relevantes sobre o impacto que suas contribuições têm sobre a qualidade e a sustentabilidade do código produzido.

Li, Zhang e Hassan [Li et al. 2025] mapearam essa transformação no corpus AIDev, identificando 932.791 Pull Requests associados a agentes de IA distribuídos em 116.211 repositórios públicos do GitHub. O subconjunto AIDev-pop, restrito a repositórios com mais de 100 estrelas, compreende 33.596 PRs agentic de 2.807 repositórios populares, produzidos pelos agentes Devin, OpenAI Codex e Claude Code.

Apesar do volume crescente de contribuições agentic, grande parte das evidências disponíveis sobre a qualidade desse código foi obtida em tarefas sintéticas, como o benchmark SWE-bench [Jimenez et al. 2024], que medem capacidade funcional em problemas isolados. Falta de estudos empíricos em Pull Requests reais de projetos open source dificulta avaliar se contribuições agentic são estruturalmente sustentáveis e qual o custo de manutenção que podem introduzir para desenvolvedores humanos responsáveis pela evolução do sistema [Dakhel et al. 2023].

Este estudo investiga, com base em PRs reais, se as contribuições de agentes autônomos de IA diferem das contribuições humanas em três dimensões de manutenibilidade definidas pela ISO/IEC 25010: manutenibilidade estrutural do código, indicadores pós-merge associados ao esforço de manutenção e dívida técnica estrutural. A análise emprega métricas de análise estática (complexidade ciclomática, code smells, Maintainability Index) e indicadores de processo (taxa de reversão, número de revisões, presença de revisão), estruturadas conforme a abordagem Goal-Question-Metric (GQM) [Basili et al. 1994]. Os agentes considerados são os classificados como autônomos pelo AIDev-pop — Devin, OpenAI Codex e Claude Code — em contribuições escritas em JavaScript, TypeScript e Python.

O restante do artigo está organizado da seguinte forma. A Seção 2 apresenta os trabalhos relacionados. A Seção 3 descreve a metodologia, incluindo a base de dados, o procedimento de identificação de PRs agentic, as questões de pesquisa com hipóteses formais, a extração de métricas, o pipeline metodológico e a análise estatística. A Seção 4 apresenta os resultados por questão de pesquisa, encerrando com uma síntese dos testes e uma discussão das limitações e ameaças à validade.

2. Trabalhos Relacionados

AIDev-pop e o paradigma de Engenharia de Software 3.0. Li, Zhang e Hassan [Li et al. 2025] apresentaram o corpus AIDev, que cataloga 932.791 PRs agentic em 116.211 repositórios do GitHub, identificando contribuições de cinco agentes (Devin, OpenAI Codex, GitHub Copilot, Cursor e Claude Code) por meio de marcadores explícitos em metadados de PR e padrões de conta. O subconjunto AIDev-pop, restrito a

repositórios com mais de 100 estrelas, abrange 33.596 PRs agentic de 2.807 repositórios populares. O estudo original concentra-se em métricas de produtividade — taxa de merge, turnaround time e distribuição de linguagens — sem investigar atributos de manutenibilidade. Este trabalho é metodologicamente complementar: utiliza o mesmo corpus para analisar qualidade estrutural, indicadores pós-merge e dívida técnica.

Análise de código gerado por Copilot. Dakhel et al. [Dakhel et al. 2023] avaliaram a qualidade do código produzido pelo GitHub Copilot em tarefas experimentais, identificando problemas estruturais recorrentes, incluindo redundâncias, padrões inadequados e dificuldades de generalização em problemas mais complexos. O estudo demonstra que, apesar de o assistente acelerar a produção, o código gerado frequentemente exige revisões e ajustes adicionais. A principal diferença em relação ao presente estudo está no contexto observacional: enquanto Dakhel et al. analisaram tarefas sintéticas controladas, este trabalho examina PRs reais submetidos em projetos open source de produção, aumentando a validade externa dos resultados.

Vieses metodológicos em Mining Software Repositories. Kalliamvakou et al. [Kalliamvakou et al. 2014] documentaram vieses recorrentes em estudos baseados em GitHub, mostrando que repositórios pouco ativos, forks e projetos pessoais podem distorcer análises empíricas se não forem adequadamente filtrados. Os autores recomendam critérios mínimos de qualidade de repositório, como atividade recente, número de estrelas e exclusão de forks. Este estudo aplica diretamente essas recomendações: o AIDev-pop seleciona repositórios não arquivados, não-forks e com mais de 100 estrelas, mitigando vieses associados a projetos de baixa relevância.

Fingerprinting comportamental de agentes de IA. Ghaleb [Ghaleb 2026] propôs uma técnica de identificação de PRs agentic baseada em 41 atributos comportamentais — padrões de mensagem de commit, estrutura do PR e características do código — atingindo F1-score de 97,2% na classificação multi-classe de cinco agentes. O autor demonstra que datasets que distinguem agentes apenas pela identidade do submissor podem conter dados mal rotulados, especialmente em fluxos híbridos em que desenvolvedores submetem código gerado por IA sob suas próprias contas. Este estudo incorpora fingerprinting como segunda camada de validação, aumentando a confiança nos rótulos do AIDev-pop e reduzindo o risco de contaminação entre os grupos.

Code smells como indicadores de manutenibilidade. Palomba et al. [Palomba et al. 2018] conduziram estudo de larga escala sobre a difusão e o impacto de code smells em centenas de projetos open source, estabelecendo evidência empírica de que classes afetadas por smells apresentam maior probabilidade de defeitos e maior esforço de manutenção. O trabalho fundamenta o uso de densidade de code smells como métrica operacional de manutenibilidade alinhada à ISO/IEC 25010. Este estudo aplica esse arcabouço metodológico ao contexto específico de comparação entre contribuições agentic e humanas.

3. Metodologia

A Figura 1 sintetiza o pipeline metodológico do estudo. A base é o AIDev-pop [Li et al. 2025], subconjunto do AIDev com 33.596 PRs agentic de 2.807 repositórios populares (>100 estrelas, não arquivados, não-forks) em JavaScript, TypeScript e Python (2023–2024). Os agentes analisados são Devin, OpenAI Codex e Claude Code. Critérios

de inclusão: diff entre 10 e 500 linhas, status merged e janela temporal ancorada na data dos primeiros PRs agentic de cada repositório.

A identificação de PRs agentic adota três camadas: (1) metadados estruturados do corpus (devin-ai-integration[bot], head:copilot/, Co-Authored-By: Claude) [Li et al. 2025]; (2) fingerprinting comportamental [Ghaleb 2026] com F1 de 97,2%; e (3) heurísticas de rastreabilidade [Mens et al. 2026] sobre artefatos do repositório (CLAUDE.md, .cursor/rules, padrões de branch). PRs cuja classificação não atingiu confiança suficiente foram alocados ao Grupo 3 (ambíguos) e excluídos da análise principal.

Após a classificação, foram obtidos 252.215 PRs: 9 no Grupo IA (G1), 202.005 no Grupo Humano (G2) e 50.201 no Grupo Ambíguo (G3, excluído). O dataset de análise comparativa reúne, portanto, 202.014 PRs (G1 + G2). As métricas de processo (review_count, has_review, is_revert, days_to_merge, test_file_ratio) foram computadas para todos os 202.014 PRs. As métricas estáticas que exigem download e parsing do diff (CCM, Maintainability Index) foram extraídas em uma amostra estratificada — todos os PRs de G1 mais uma amostra de G2 —, resultando em $n = 3$ (G1) e $n = 32$ (G2) PRs com funções analisáveis para CCM/MI, e $n = 9$ (G1) e $n = 50$ (G2) para densidade de smells e tipos de smell.

O estudo investiga sete RQs em três dimensões, com hipóteses H0 (ausência de diferença) e H1 (presença de diferença) e $\alpha = 0,05$. **Q1 – Estrutural:** RQ01 (CCM), RQ02 (smells/KLoC). **Q2 – Pós-Merge:** RQ03 (reversão), RQ04 (rodadas de revisão). **Q3 – Dívida técnica:** RQ05 (smells de design/KLoC), RQ06 (Maintainability Index), RQ07 (tipos de smell).

CCM [McCabe 1976] e MI [Heitlager et al. 2007] são extraídos pelo Lizard em modo incremental sobre o diff. Nesta execução, os detectores ESLint e Pylint não foram acionados; a densidade de smells de design foi aproximada pelo Lizard (funções longas, NLOC > 50, normalizadas por KLoC), e o MI foi calculado sem o volume de Halstead, o que tende a subestimar ligeiramente o índice. Indicadores pós-merge vêm da GitHub API; LoC Delta é controle. Para contínuas: Mann-Whitney U + Cliff's δ (Romano et al.: negligível $|\delta| < 0,147$; pequeno $< 0,33$; médio $< 0,474$; grande $\geq 0,474$). Binárias: Fisher; categóricas: Qui-quadrado. Todas ajustadas por Benjamini-Hochberg e Bonferroni.

4. Resultados

A Tabela 1 apresenta a proporção de PRs com pelo menos uma revisão humana formal.

Table 1. Proporção de PRs com Revisão Formal (has_review).				
Grupo	N total	Com revisão (n)	Com revisão (%)	p-value (Fisher)
IA (G1)	9	5	55,6 %	0,257
Humano (G2)	202.005	148.564	73,5 %	

A diferença observada em has_review (55,6 % em G1 contra 73,5 % em G2) **não é estatisticamente significativa:** o teste exato de Fisher retornou $p = 0,257$. A seguir, apresentam-se os resultados por questão de pesquisa.

4.1. Q1: Manutenibilidade Estrutural

RQ01 – CCM. A Figura 2 mostra a distribuição da complexidade ciclomática média por grupo ($n = 3$ em G1; $n = 32$ em G2). Em contraste com o esperado, G1 apresenta mediana mais alta ($\approx 5,4$) do que G2 ($\approx 1,25$), com Cliff's $\delta = 0,71$ (efeito grande). O teste Mann-Whitney U retornou p bruto $= 0,043$ (limítrofe), mas **a diferença não é estatisticamente significativa** após correção para múltiplos testes ($p_{BH} = 0,142$; $p_{Bonf} = 0,681$). Dado o tamanho amostral mínimo de G1 ($n = 3$), o resultado deve ser interpretado como indício exploratório, não como evidência robusta. **H0 não rejeitada** com $\alpha = 0,05$.




Figure 2. Distribuição de `ccm_mean` por grupo ($n = 3$ G1; $n = 32$ G2). G1 apresenta mediana mais alta ($\approx 5,4$) que G2 ($\approx 1,25$). Diferença não significativa após correção; amostra G1 muito pequena.

RQ02 – Densidade de Code Smells / KLoC. Os detectores ESLint e Pylint não foram executados nesta análise; o indicador disponível é a densidade de smells de design aproximada pelo Lizard (ver RQ05). Sobre essa proxy, o teste Mann-Whitney U não indicou diferença estatisticamente significativa entre G1 e G2 ($p = 0,612$; $\delta = 0,049$, negligível). **H0 não rejeitada** com $\alpha = 0,05$.




Figure 1. Pipeline metodológico do estudo.

4.2. Q2: Indicadores Pós-Merge

RQ03 – Taxa de Reversão. Nenhum dos 9 PRs de G1 foi revertido (0 %), contra 6.813 de 202.005 em G2 ($\approx 3,4\%$). O teste exato de Fisher retornou $p = 1,0$, sem diferença estatisticamente significativa. **H0 não rejeitada** com $\alpha = 0,05$.

RQ04 – Número de Rodadas de Revisão. A Figura 3 apresenta a distribuição de `review_count` por grupo. Ambos os grupos têm mediana igual a 1; G1 concentra-se em 0–4 revisões, enquanto G2 apresenta cauda superior estendida até 30. O teste Mann-Whitney U retornou $p = 0,411$ com Cliff's $\delta = -0,153$ (efeito pequeno), **sem diferença estatisticamente significativa. H0 não rejeitada** com $\alpha = 0,05$.




Figure 3. Distribuição de `review_count` por grupo ($p = 0,411$; Cliff's $\delta = -0,153$). Mediana igual a 1 em ambos; diferença não significativa.

A Figura 4 mostra a distribuição de `days_to_merge` em escala logarítmica. G1 concentra-se próximo a zero (mediana $\approx 0,04$ dia), assim como G2 (mediana $\approx 0,62$ dia), que exibe maior variância e outliers até $\sim 7,7$ (em log). O teste Mann-Whitney U **não indicou diferença significativa** ($p = 0,305$; $\delta = -0,197$, pequeno).




Figure 4. Distribuição de `days_to_merge` em escala log ($p = 0,305$; $\delta = -0,197$). Diferença não significativa.

4.3. Q3: Dívida Técnica Estrutural

RQ05 – Densidade de Code Smells de Design / KLoC. O teste Mann-Whitney U sobre `design_smell_density` ($n = 9$ G1; $n = 50$ G2; proxy via Lizard) não indicou diferença estatisticamente significativa entre os grupos ($p = 0,612$; $\delta = 0,049$, negligível). Ambas as medianas são iguais a zero. **H0 não rejeitada** com $\alpha = 0,05$.

RQ06 – Maintainability Index. A Figura 5 apresenta a distribuição de `maintainability_index` por grupo ($n = 3$ G1; $n = 32$ G2). G1 concentra-se em torno de 49–50 (mediana $\approx 49,6$); G2 apresenta mediana mais alta ($\approx 61,4$), com Cliff's $\delta = -0,625$ (efeito grande). O teste Mann-Whitney U retornou $p = 0,082$, **sem diferença significativa**. Apesar do tamanho de efeito grande, o resultado não é robusto dado o n mínimo de G1 ($n = 3$). **H0 não rejeitada** com $\alpha = 0,05$.




Figure 5. Distribuição de `maintainability_index` por grupo ($n = 3$ G1; $n = 32$ G2). G1 mediana $\approx 49,6$; G2 mediana $\approx 61,4$. Diferença não significativa após correção; amostra G1 muito pequena.

RQ07 – Distribuição dos Tipos de Code Smell. A Figura 6 mostra a distribuição de `smell_type` ($n = 9$ G1; $n = 50$ G2). Ambos os grupos são dominados por PRs sem smell (*none*: 78 % em G1, 76 % em G2). G1 apresenta maior proporção de smells de *complexity* (22 % vs. 6 %), ao passo que G2 concentra os smells de *style* (12 % vs. 0 %) e *size* (6 % vs. 0 %). O teste Qui-quadrado retornou $p = 0,262$, **sem diferença estatisticamente significativa**. **H0 não rejeitada** com $\alpha = 0,05$.




Figure 6. Distribuição dos tipos de `smell_type` por grupo ($n = 9$ G1; $n = 50$ G2). Predominância de *none* (78 % G1; 76 % G2). Diferença não significativa.

4.4. Síntese dos Testes

A Tabela 2 consolida os resultados estatísticos por métrica. **Nenhuma das sete hipóteses das questões de pesquisa foi rejeitada após correção para múltiplos testes.** A única variável com diferença robusta foi a distribuição de linguagens (`language`), uma variável descritiva de controle: o Qui-quadrado retornou $p = 0,0015$, mantendo significância após Benjamini-Hochberg e Bonferroni ($p_{\text{adj}} = 0,0236$), embora com tamanho de efeito negligível ($\delta = 0,008$). Esse resultado apenas reflete a composição amostral — G1 é majoritariamente Python (8 de 9 PRs), enquanto G2 é dominado por TypeScript — e não diz respeito à manutenibilidade. Alguns sinais brutos (CCM mais alta e MI mais baixo em G1; menor proporção de arquivos de teste e de arquivos alterados) surgiram com $p < 0,05$ antes da correção, mas todos se dissolveram após o ajuste para múltiplos testes e repousam sobre uma amostra G1 mínima.

Table 2. Resumo dos resultados estatísticos por métrica (estrato a11).

Métrica	Teste	p bruto	B-H	Bonf.	Cliff's δ / Decisão
<code>language</code>	Qui-quadrado	0,0015	Sig.	Sig.	0,008 (neglig.) – controle, robusto
<code>ccm.mean</code>	Mann-Whitney	0,043	Não sig.	Não sig.	0,71 (grande) – H0 não rejeitada
<code>maintainability_index</code>	Mann-Whitney	0,082	Não sig.	Não sig.	-0,625 (grande) – H0 não rejeitada
<code>review_count</code>	Mann-Whitney	0,411	Não sig.	Não sig.	-0,153 (pequeno) – H0 não rejeitada
<code>has_review</code>	Fisher	0,257	Não sig.	Não sig.	-- H0 não rejeitada
<code>design_smell_density</code>	Mann-Whitney	0,612	Não sig.	Não sig.	0,049 (neglig.) – H0 não rejeitada
<code>is_revert</code>	Fisher	1,000	Não sig.	Não sig.	-- H0 não rejeitada
<code>days_to_merge</code>	Mann-Whitney	0,305	Não sig.	Não sig.	-0,197 (pequeno) – H0 não rejeitada
<code>smell_type</code>	Qui-quadrado	0,262	Não sig.	Não sig.	H0 não rejeitada

4.5. Limitações e Ameaças à Validade

O principal fator limitante deste estudo é o tamanho do Grupo IA. Dos 295 PRs agentic identificados pelos rótulos do AIDev-pop nos repositórios coletados, apenas 9 sobreviveram aos critérios de inclusão (diff de 10–500 linhas, linguagens JS/TS/Python e janela temporal), e desses, somente 3 possuíam funções analisáveis para as métricas estáticas de código (CCM e MI). Além disso, os 9 PRs de G1 concentram-se em um único repositório (`Significant-Gravitas/AutoGPT`), o que compromete a representatividade e a validade externa. Com $n = 9$ (e $n = 3$ para CCM/MI), o poder estatístico é muito baixo, e os efeitos de tamanho grande observados em `ccm.mean` e `maintainability_index` não puderam ser confirmados após correção. Os resultados devem, portanto, ser lidos como exploratórios e preliminares.

Há ainda limitações de instrumentação: os detectores ESLint e Pylint não foram executados nesta rodada, de modo que a densidade de smells (RQ02 e RQ05) foi aproximada por uma heurística do Lizard (funções longas por KLoC), não capturando violações de convenção e de acoplamento; e o Maintainability Index foi calculado sem o volume de Halstead, subestimando ligeiramente o índice. A forte assimetria amostral (202.005 PRs humanos contra 9 de IA) também torna os testes não paramétricos sensíveis a desbalanceamento. Trabalhos futuros devem ampliar a amostra agentic — relaxando os filtros de coleta ou focando repositórios com maior concentração de PRs de agentes — e habilitar os detectores de smells completos antes de extrair conclusões sobre manutenibilidade.

References

- Basili, V., Caldiera, G., and Rombach, H. D. (1994). The goal question metric approach. In *Encyclopedia of Software Engineering*. Wiley.
- Dakhel, A. M. et al. (2023). GitHub Copilot AI pair programmer: Asset or liability? *Journal of Systems and Software*.
- Finnie-Ansley, J. et al. (2023). It's weird that it knows what I want. *ACM TOCHI*.
- Ghaleb, T. A. (2026). Fingerprinting AI coding agents on GitHub. In *MSR '26*.
- Heitlager, I., Kuipers, T., and Visser, J. (2007). A practical model for measuring maintainability. In *QUATIC*.
- Jimenez, C. E. et al. (2024). SWE-bench: Can language models resolve real-world GitHub issues? In *ICLR*.
- Kalliamvakou, E. et al. (2014). The promises and perils of mining GitHub. In *ACM MSR*.
- Li, H., Zhang, H., and Hassan, A. E. (2025). The rise of AI teammates in software engineering (SE) 3.0. *arXiv:2507.15003*.
- McCabe, T. J. (1976). A complexity measure. *IEEE Transactions on Software Engineering*.
- Mens, T. et al. (2026). Agentic much? adoption of coding agents on GitHub. In *MSR '26*.
- Palomba, F. et al. (2018). On the diffuseness and the impact on maintainability of code smells. *Empirical Software Engineering*.
- Vaithilingam, P. et al. (2022). Expectation vs. experience: Evaluating AI code assistants in practice. In *ACM CHI*.